News Collect

뉴스 수집 · 본문 추출 · DB 저장 파이프라인

Technical Architecture & API Reference

Version 1.0 | 2026-08-05 | Confidential — Internal Use

항목	내용
문서 유형	시스템 기술 명세서 / API 레퍼런스
대상 시스템	news_collect (Flask RSS Ingestion Service)
주요 독자	백엔드·프론트엔드 연동 개발자, 아키텍트
Base URL	http://<host>:5000
데이터 저장소	PostgreSQL (news_collect)

본 문서는 뉴스 RSS 수집부터 본문 추출, PostgreSQL 적재까지의 전체 데이터 파이프라인, 기술 스택, REST API 명세, 프론트엔드 연동 시나리오를 정의한다. 테스트 UI는 디버깅용이며, 프로덕션 배치는 sources 테이블 기준 전체 저장 API를 사용한다.

목차

1. 개요 및 시스템 목표
2. 기술 스택
3. 아키텍처 및 데이터 모델
4. 수집 → 저장 엔드투엔드 플로우
5. Google News 원천·파생 소스 모델
6. API 전체 목록 및 상세 명세
7. 프론트엔드 연동 시나리오 (API 사용 예시)
8. 오류 처리 · 품질 게이트 · 성능
9. 운영 및 연동 가이드라인

1. 개요 및 시스템 목표

News Collect는 다수 언론·포털 RSS 피드를 수집하고, 기사 원문 HTML에서 본문을 추출한 뒤 PostgreSQL에 구조화하여 저장하는 인제스천(Ingestion) 서비스이다. 웹 UI는 수집 품질을 검증하기 위한 테스트·디버그 콘솔이며, 실제 운영 배치의 기준 데이터는 sources / articles 테이블이다.

1.1 핵심 목표

- 언론사별 RSS 및 Google News 키워드 RSS를 단일 파이프라인으로 수집
- 봇 차단·인코딩·사이트 구조 차이에 강건한 HTTP 및 본문 추출
- 본문 수집 실패 기사 제외, URL 기준 중복 방지
- Google News 파생 소스와 일반 RSS 소스의 명확한 분리 및 배치 수집 정책
- 메인 서비스(프론트/배치)가 호출 가능한 명시적 REST API 제공

1.2 논리적 구성요소

구성	책임	비고
Test UI	출처 관리, 단건 미리보기, 진행 로그	categories.json 중심
Collection API	RSS 파싱 · 본문 추출	동기 / NDJSON 스트림
Persistence API	sources·articles 적재	전체 저장은 DB sources 기준
PostgreSQL	영속 저장소	UNIQUE source_url 로 멱등성

2. 기술 스택

2.1 계층별 기술

계층	기술	역할
프레젠테이션	HTML / CSS / Vanilla JS	테스트·디버그 UI, 진행 로그
API 계층	Flask + flask-cors	REST JSON / NDJSON 스트림
수집 엔진	feedparser, curl_cffi, requests	RSS 파싱, 브라우저 impersonate
본문 추출	readability-lxml, BeautifulSoup	사이트별 전용 파서 포함
URL 해석	googlenewsdecoder	Google News 리다이렉트 해제
병렬 처리	concurrent.futures	피드·기사 단위 ThreadPool
영속 계층	PostgreSQL + psycopg3	sources / articles
설정	categories.json, config.json	출처 목록 · DB 접속 정보

그림 2-1. 계층별 기술 스택 요약

2.2 주요 라이브러리 역할

패키지	역할
Flask / flask-cors	HTTP API 서버, CORS, 스트리밍 응답
feedparser	RSS/Atom XML 파싱
curl_cffi	Chrome TLS/JA3 impersonate — Cloudflare 등 우회
requests	HTTP 폴백
readability-lxml	본문 후보 영역 추출 (Mozilla Readability)
beautifulsoup4 / lxml	HTML 파싱, 사이트별 DOM 추출
googlenewsdecoder	Google News 기사 토큰 → 원문 URL
python-dateutil	발행일 파싱 및 로컬 타임존 날짜 변환
psycopg (v3)	PostgreSQL 접속 및 트랜잭션
chardet	응답 인코딩 추정

2.3 런타임·인프라 가정

- Python 3.12+ (개발 환경 기준 3.14 동작 확인)
- PostgreSQL 14+ , DB명 기본값 news_collect
- 접속 정보는 config.json 의 database 블록
- 개발 서버: Flask debug, port 5000 (운영 시 WSGI 권장)

3. 아키텍처 및 데이터 모델

3.1 논리 아키텍처

클라이언트(테스트 UI 또는 메인 프론트) → Flask API → 수집 엔진(RSS/HTTP/추출) → PostgreSQL. 설정 파일(categories.json)은 UI 테스트용 출처 목록이고, 배치 수집의 진실 공급원(Source of Truth)은 sources 테이블이다.



그림 3-1. 논리 아키텍처 개요

3.2 sources 테이블

```
CREATE TABLE sources (
  source_id          BIGINT GENERATED BY DEFAULT AS IDENTITY PRIMARY KEY,
  name               VARCHAR(200) NOT NULL,
  rss_url            VARCHAR(1000) UNIQUE,
  source_type        VARCHAR(20) NOT NULL
    CHECK (source_type IN ('공식발표','통신사','전문미디어','포털API','커뮤니티')),
  credibility_weight NUMERIC(3,2) NOT NULL CHECK (0..1),
  created_at         TIMESTAMPTZ NOT NULL DEFAULT now()
);
```

3.3 articles 테이블

```
CREATE TABLE articles (
  article_id      BIGINT GENERATED BY DEFAULT AS IDENTITY PRIMARY KEY,
  source_id       BIGINT NOT NULL REFERENCES sources(source_id),
  source_url      VARCHAR(1000) NOT NULL UNIQUE,  -- 원문 URL, 중복 스킵 키
  title           VARCHAR(500) NOT NULL,
  cleaned_content TEXT,       -- 추출 본문
  raw_content     TEXT,       -- 원문 HTML
  published_at    TIMESTAMPTZ,
  collected_at    TIMESTAMPTZ NOT NULL DEFAULT now(),
  status          VARCHAR(20) DEFAULT 'collected'
    CHECK (status IN ('collected','processed','summarized','archived'))
);
```

3.4 소스 유형 매트릭스 (운영 핵심)

종류	name 예시	rss_url 예시	전체 저장
일반 언론 RSS	매일경제 - 경제	https://www.mk.co.kr/rss/...	전체 저장 O · 자체 RSS 수집
GN 원천	Google News · 증권	https://news.google.com/rss/search?q=...	전체 저장 O · 키워드 수집 트리거
GN 파생	매일경제 - 증권 (GN)	google_news://증권/매일경제	전체 저장 X · 기사 적재 전용

표 3-1. 소스 유형별 식별자 및 전체 저장 포함 여부

규칙 요약: 전체 저장 대상 = http(s) RSS 이면서 rss_url NOT LIKE 'google_news://%' 이고 name NOT LIKE '%(GN)'. 파생 소스는 기사 적재 대상일 뿐, 배치 수집 루프의 입력으로 사용하지 않는다.

4. 수집 → 저장 엔드투엔드 플로우

4.1 단계별 파이프라인

단계	프로세스	설명
1	출처 등록	categories.json 및/또는 sources 테이블 (일반 RSS / Google News 키워드)
2	RSS 수집	feedparser + curl_cffi (Cloudflare 대응)
3	날짜 필터	로컬 타임존 기준 오늘 / 오늘+어제
4	URL 해석	Google News → 원문 URL (googlenewsdecoder)
5	본문 추출	사이트 전용 파서 → Readability → BS4
6	품질 검증	푸터/AI요약/잘림 거부, 본문 실패 시 미저장
7	DB 적재	sources upsert → articles insert (URL UNIQUE)

표 4-1. 인제스천 파이프라인 7단계

4.2 단건 수집 (UI 테스트 / 미리보기)

사용자가 카테고리·소스를 선택하면 프론트는 POST /api/fetch-stream 을 호출한다. 서버는 RSS를 읽고 날짜 필터 후 기사별로 병렬 본문 추출을 수행하며, 진행 상황을 NDJSON 으로 푸시한다. DB에는 쓰지 않는다.

4.3 단건 수집 + 저장

POST /api/fetch-and-save-stream: 수집 후 저장. type=RSS 이면 sources.name/url 로 upsert 후 동일 source_id 에 articles insert. type=GOOGLE_NEWS 이면 기사마다 publisher 를 읽어 {언론사} - {키워드} (GN) 파생 source 를 만들고 그 ID 로 저장한다.

4.4 전체 DB 저장 (프로덕션 배치 경로)

POST /api/save-all-stream 이 운영의 기본 진입점이다. categories.json 이 아니라 list_collectible_sources() 결과(DB)를 순회한다. 피드 병렬(기본 4) × 기사 병렬(배치 시 기본 4)로 처리한다. Google News 원천 URL(news.google.com)은 GOOGLE_NEWS 경로로 수집하고, 기사는 파생 (GN) 소스에 적재한다. 파생 소스 자체는 순회 목록에 없다.

4.5 본문 추출 우선순위

우선순위	방법	대상 예
0	사이트 전용 파서	조선 Fusion, 한경, 동아, 매경, GeekNews
1	Readability	일반 뉴스 페이지
2	JSON-LD articleBody	스키마 제공 사이트 (잘린 본문 거부)
3	BeautifulSoup 셀렉터	공통 CSS 후보

거부 조건: 언론사 푸터 오탐, AI 요약 블록(매경 핵심요약 쏙 등), 말줄임(...)으로 끝나는 잘린 본문, 본문 공백/실패 문구. 실패 기사는 DB에 넣지 않고 no_content 로 집계한다.

5. Google News 원천·파생 소스 모델

Google News 검색 RSS는 단일 언론사가 아니라 다수 언론 기사를 묶는다. 따라서 원천 키워드 피드와 기사 단위 언론사 소스를 분리한다.

5.1 등록 시

UI에서 Google News + 키워드 추가 시:
1) categories.json 에 type=GOOGLE_NEWS 항목 추가
2) sources 에 원천 행 INSERT — name=Google News · {키워드}, rss_url=실제 news.google.com 검색 URL, source_type=포털API

5.2 수집·저장 시

1) Google RSS entry 의 source.title → publisher
2) googlenewsdecoder 로 원문 URL 해석
3) 원문 본문 추출
4) sources upsert: name={publisher} - {keyword} (GN), rss_url=google_news://{keyword}/{publisher}
5) articles.insert(source_id=파생 ID)

일반 RSS 매일경제 - 경제 와 파생 매일경제 - 경제 (GN) 은 이름·URL 모두 달라 충돌하지 않는다. 파생 소스는 rss_url 로만 매칭한다.

5.3 전체 저장 포함/제외

소스	전체 저장 루프	기사 적재
Google News · 증권 (원천)	포함 — 키워드 수집 실행	직접 적재하지 않음 (트리거)
매일경제 - 증권 (GN) (파생)	제외	GN 수집 시 적재
매일경제 - 경제 (일반 RSS)	포함 — 자체 RSS 수집	해당 source_id 로 적재

6. API 전체 목록 및 상세 명세

6.1 엔드포인트 총괄

Method	Path	설명
GET	/	테스트 UI
GET	/api/categories	카테고리·출처 목록
POST	/api/add-source	출처 추가 (RSS / GOOGLE_NEWS)
POST	/api/delete-source	출처 삭제 (categories.json)
POST	/api/fetch	단건 수집 (미리보기)
POST	/api/fetch-stream	단건 수집 + 진행 스트림
POST	/api/fetch-and-save	단건 수집 + DB 저장
POST	/api/fetch-and-save-stream	단건 수집·저장 + 스트림
POST	/api/save-all	전체 저장 (sources 기준)
POST	/api/save-all-stream	전체 저장 + 스트림 ★
GET	/api/test	전 피드 연결 스모크 테스트
GET	/api/db-stats	DB 적재 통계

표 6-1. API 엔드포인트 목록 (Base URL: http://host:5000)

6.2 공통 규칙

- Content-Type: application/json (스트림 제외)
- 스트림 API: application/x-ndjson , 라인 단위 JSON
- 성공/실패: 대부분 { success: bool, ... } 또는 HTTP 4xx/5xx
- 날짜 필터: 서버 로컬 타임존 달력 기준 (UTC date() 직접 사용 안 함)
- 본문 실패 문구: "본문을 가져올 수 없습니다." — DB 미저장

6.3 엔드포인트별 상세

GET / [UI]

테스트 콘솔 HTML 반환. 인증 없음.

GET /api/categories [설정]

categories.json 전체 로드. 응답: { categories: { [cat]: Source[] } }. Source: name, url, type(RSS|GOOGLE_NEWS), keyword?(GN).

POST /api/add-source [설정]

Body(RSS): { category, type:'RSS', name, url }. Body(GN): { category, type:'GOOGLE_NEWS', keyword }. GN은 categories.json + sources 원천 동시 등록. 409 중복, 400 검증 오류.

POST /api/delete-source [설정]

Body: { category, source_name }. categories.json 에서만 삭제. DB sources 행은 현재 자동 삭제하지 않음.

POST /api/fetch [수집]

Body: { url, type?, keyword?, name?, include_yesterday?, limit? }. 수집만 수행. articles[] 반환. is_google_news, failed 카운트 포함.

POST /api/fetch-stream [수집]

fetch 와 동일 파라미터. NDJSON progress + done.data.

POST /api/fetch-and-save [수집+저장]

수집 후 DB 저장. Body에 name 권장. 응답: today_articles, failed, db:{saved,skipped,no_content,errors}.

POST /api/fetch-and-save-stream [수집+저장]

위와 동일 + NDJSON 진행 스트림.

POST /api/save-all [배치]

DB sources 수집 가능 목록 전체 처리. Body 없음. 동기 JSON. detail[] 에 출처별 결과.

POST /api/save-all-stream [배치 ★]

save-all 의 스트리밍 버전. 프로덕션 배치·UI 전체 저장 권장.

GET /api/test [디버그]

categories.json 전 피드 limit=1 스모크. 시간 소요 큼.

GET /api/db-stats [모니터링]

sources_count, articles_count, top_sources[] 반환.

6.4 수집 공통 요청 필드

필드	타입	필수	설명
url	string	Y	RSS URL
type	string	N	RSS | GOOGLE_NEWS (기본 RSS)
keyword	string	GN 시	검색 키워드, 파생 source 이름에 사용
name	string	N	로그·표시용 출처명
include_yesterday	bool	N	true=오늘+어제
limit	int	N	피드 entry 상한(디버그)

6.5 수집 응답 article 객체

필드	설명
title	정제된 제목 (GN은 언론사 접미 제거)
content	추출 본문 또는 실패 문구
raw_content	원문 HTML (저장 시 articles.raw_content)
link	원문 URL (GN은 해석 후 URL)
published	RSS 발행 시각 문자열
method	추출기 이름 (MkBody, ChosunFusion, Readability, 실패 등)
publisher	언론사 (주로 GN)
keyword	GN 키워드

6.6 NDJSON 스트림 포맷

```
{"type":"progress","message":"매일경제 - 경제 · 수집 중... 3/12건","phase":"collecting","current":3,"total":12}
{"type":"progress","message":"매일경제 - 경제 · 저장 완료 · 저장 10","phase":"saved"}
{"type":"done","success":true,"data":{ ... 최종 결과 객체 ... }}
{"type":"done","success":false,"error":"에러 메시지"}
```

phase 예: batch_start, feed_start, fetch_rss, collect_start, collecting, collect_done, saving, saved, batch_progress, batch_done, error, feed_error

7. 프론트엔드 연동 시나리오 (API 사용 예시)

아래 예시는 메인 웹앱(React/Vue/Next 등) 또는 배치 워커가 동일 API를 호출하는 패턴이다. Base URL 은 환경변수로 주입한다.

7.1 시나리오 A — 출처 목록 로드

```
GET /api/categories

// 응답을 카테고리 탭 + 소스 칩으로 렌더
// type==='GOOGLE_NEWS' 이면 배지 GN, label=keyword
const { categories } = await res.json();
Object.entries(categories).forEach(([cat, sources]) => { ... });
```

7.2 시나리오 B — 일반 RSS 출처 등록

```
POST /api/add-source
Content-Type: application/json

{
  "category": "경제/경영",
  "type": "RSS",
  "name": "연합뉴스 - 경제",
  "url": "https://www.yna.co.kr/rss/economy.xml"
}

// 성공 시 categories 전체를 다시 받아 상태 갱신
// 실제 sources 테이블 반영은 이후 fetch-and-save 또는 배치 시 upsert
```

7.3 시나리오 C — Google News 키워드 등록

```
POST /api/add-source

{
  "category": "IT",
  "type": "GOOGLE_NEWS",
  "keyword": "인공지능"
}

// 서버 동작:
// 1) categories.json 에 GOOGLE_NEWS 항목 추가
// 2) sources 에 원천 INSERT
//    name="Google News · 인공지능"
//    rss_url=https://news.google.com/rss/search?q=...
//    source_type="포털API"
// 응답 source.source_id, source.db_created 확인
```

7.4 시나리오 D — 단건 미리보기 (수집만)

```
POST /api/fetch-stream

{
  "url": "https://www.mk.co.kr/rss/30100041/",
  "type": "RSS",
  "name": "매일경제 - 경제",
  "include_yesterday": false
}

// 클라이언트: ReadableStream 으로 줄 단위 JSON 파싱
// type==='progress' → 토스트/로그 UI 갱신
// type==='done' && success → data.articles 로 리스트 렌더
// article.publisher 있으면 언론사 뱃지 표시 (주로 GN)
```

7.5 시나리오 E — 단건 수집 후 DB 저장

```
POST /api/fetch-and-save-stream

{
  "name": "Google News · 증권",
```

```
  "url": "https://news.google.com/rss/search?q=%EC%A6%9D%EA%B6%8C&hl=ko&gl=KR&ceid=KR:ko",
  "type": "GOOGLE_NEWS",
  "keyword": "증권",
  "include_yesterday": true
}

// 진행 로그 예:
// "Google News · 증권 · RSS 불러오는 중..."
// "Google News · 증권 · 수집 중... 5/20건"
// "Google News · 증권 · DB 저장 중... (20건)"
// "Google News · 증권 · 저장 완료 · 저장 15건"
// done.data.db = { saved, skipped, no_content, errors }
// 기사별 sources 예: "한겨레 - 증권 (GN)", rss_url=google_news://증권/한겨레
```

7.6 시나리오 F — 프로덕션 일배치 (전체 저장) ★

스케줄러(cron, Airflow, Cloud Scheduler 등) 또는 관리자 UI 버튼이 호출한다. UI의 categories.json 과 무관하게, 그 시점 DB sources 의 수집 가능 행만 처리한다.

```
POST /api/save-all-stream
Content-Type: application/json

{}

// 서버 내부:
// sources WHERE http(s) AND NOT google_news:// AND name NOT LIKE '% (GN)'
// 각 source:
//   - news.google.com 이면 type=GOOGLE_NEWS, keyword 복원 후 수집
//     → 기사는 파생 (GN) source 로 insert
//   - 그 외 RSS 는 type=RSS
//     → 해당 source_id 로 insert
// 병렬: feed_workers=4, article_workers_per_feed=4 (설정값)

// done.data:
// {
//   "total_saved": 152,
//   "total_skipped": 40,
//   "total_no_content": 8,
//   "detail": [ { name, source_id, success, db:{...} }, ... ],
//   "parallel": { "feed_workers": 4, "article_workers_per_feed": 4 }
// }
```

7.7 시나리오 G — 프론트에서 sources 목록 정책

메인 앱이 수집 가능 언론 목록을 보여줄 때 SELECT * FROM sources 를 그대로 쓰면 파생 (GN) 행까지 노출된다. 수집 대상으로 쓸 목록은 아래와 동일 조건으로 필터한다.

```
-- 수집 대상 sources (서버 list_collectible_sources 와 동일 취지)
SELECT source_id, name, rss_url, source_type
FROM sources
WHERE rss_url IS NOT NULL
  AND rss_url <> ''
  AND rss_url NOT LIKE 'google_news://%'
  AND name NOT LIKE '% (GN)'
  AND (rss_url LIKE 'http://%' OR rss_url LIKE 'https://%')
ORDER BY source_id;

-- 기사 피드는 보통 articles 기준 조회 (파생 source 기사 포함 가능)
SELECT a.*, s.name AS source_name
FROM articles a
JOIN sources s ON s.source_id = a.source_id
WHERE a.published_at >= now() - interval '1 day'
ORDER BY a.published_at DESC;
```

7.8 NDJSON 클라이언트 의사코드

```
async function readNdjson(url, body, onProgress) {
  const res = await fetch(url, {
    method: 'POST',
    headers: { 'Content-Type': 'application/json' },
    body: JSON.stringify(body || {}),
```

```
  });
  const reader = res.body.getReader();
  const dec = new TextDecoder();
  let buf = '', final = null;
  while (true) {
    const { value, done } = await reader.read();
    if (done) break;
    buf += dec.decode(value, { stream: true });
    const lines = buf.split('₩n'); buf = lines.pop();
    for (const line of lines) {
      if (!line.trim()) continue;
      const obj = JSON.parse(line);
      if (obj.type === 'progress') onProgress(obj);
      if (obj.type === 'done') final = obj;
    }
  }
  return final; // { success, data } | { success:false, error }
}
```

8. 오류 처리 · 품질 게이트 · 성능

8.1 저장 게이트

조건	결과
본문 null / 공백 / 실패 문구	no_content, INSERT 안 함
source_url 이미 존재	skipped (중복)
본문 정상 + 신규 URL	saved
기타 DB 오류	errors

8.2 추출 품질 필터

- 사이트 푸터(등록번호, 발행·편집인 등) 오탐 거부
- 매경 등 AI 요약 모달(Key Points, OpenAI 문구) 제거·거부
- 말줄임(...) 으로 끝나는 잘린 JSON-LD/본문 거부 (GeekNews 등)
- 조선: Fusion.globalContent / 동아: section.news_view / 한경: .article-body 등

8.3 성능 파라미터

파라미터	기본값	의미
_ARTICLE_WORKERS	8	단건 수집 시 기사 병렬 수
_FEED_WORKERS	4	전체 저장 시 소스 병렬 수
_ARTICLE_WORKERS_IN_BATCH	4	전체 저장 시 소스당 기사 병렬
GN URL 캐시	프로세스 메모리	동일 구글 링크 재해석 방지

대략 동시 HTTP feed_workers × article_workers_in_batch. 과도한 상향은 대상 사이트 차단 위험이 있다.

8.4 HTTP 상태 가이드

코드	상황
200	정상 JSON / 스트림 완료
400	필수 파라미터 누락·검증 실패
404	delete-source 시 카테고리/출처 없음
409	중복 출처/키워드
500	서버·DB·수집 예외

9. 운영 및 연동 가이드라인

9.1 환경 설정

```
// config.json
{
  "database": {
    "host": "localhost",
    "port": 5432,
    "dbname": "news_collect",
    "user": "postgres",
    "password": "****"
  }
}
```

9.2 메인 서비스 연동 체크리스트

- 프로덕션 배치는 POST /api/save-all-stream 사용 (진행 관측 + 타임아웃 여유)
- 수집 가능 소스 목록 UI는 list_collectible_sources 조건과 동일한 필터 적용
- 기사 피드는 articles 조인 조회; (GN) 소스 기사 포함 여부는 제품 정책에 따름
- categories.json 은 테스트 UI 전용으로 취급, 배치 SoT 는 sources 테이블
- 삭제 API의 DB 연동(원천/파생 cascade)이 필요하면 후속 개발 항목으로 명시
- 운영 배포 시 Flask dev 서버 대신 gunicorn/waitress + reverse proxy
- Google/언론사 rate limit 모니터링, 워커 수 조정

9.3 권장 호출 맵 (메인 앱)

사용자/시스템 행동	API
관리: RSS/키워드 등록	POST /api/add-source
관리: 테스트 UI 목록	GET /api/categories
운영: 매일 배치 수집	POST /api/save-all-stream
운영: 특정 소스만 재수집	POST /api/fetch-and-save-stream
모니터링: 적재량	GET /api/db-stats
디버그: 본문 품질 확인	POST /api/fetch-stream

문서 끝. 본 명세는 news_collect 코드베이스(app.py, db.py, schema.sql, 프론트 static) 구현 시점 기준이다. API 변경 시 본 문서와 버전을 함께 갱신한다.